CEFET/RJ

PROCESSAMENTO DE CONSULTA

Eduardo Ogasawara
eogasawara@ieee.org
https://eic.cefet-rj.br/~eogasawara

Etapas básicas no processamento da consulta

- Análise e tradução
- Otimização
- Avaliação

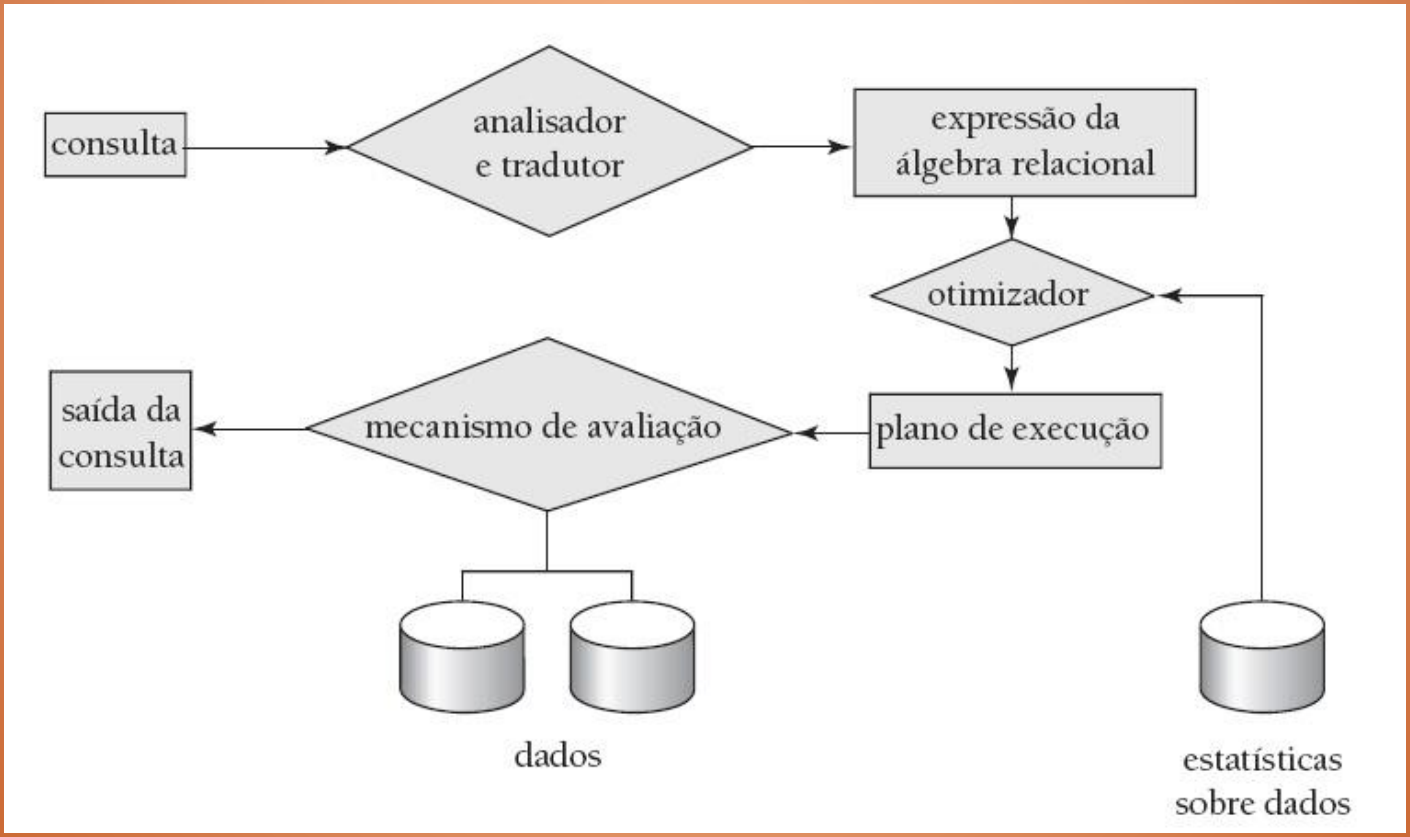

Etapas básicas no processamento da consulta: Análise e tradução & Avaliação

- Análise e tradução
  - Traduz a consulta para o seu formato interno
  - Este é então traduzido para a álgebra relacional
  - O analisador verifica a sintaxe e as relações
- Avaliação
  - O mecanismo de execução de consulta produz um plano de avaliação de consulta
  - Executa esse plano
  - Retorna as respostas à consulta

Etapas básicas no processamento da consulta: Otimização

- Uma expressão da álgebra relacional pode ter muitas expressões equivalentes
  - $\boldsymbol{\sigma}_{saldo<2500}(\boldsymbol{\pi}_{saldo}(conta))$ é equivalente a $\boldsymbol{\pi}_{saldo}(\boldsymbol{\sigma}_{saldo<2500}(conta))$
- Cada operação da álgebra relacional pode ser avaliada usando um dos vários algoritmos possíveis
  - Da mesma forma, uma expressão da álgebra relacional pode ser avaliada de muitas maneiras
- Expressão anotada especificando estratégia de avaliação detalhada é chamada de plano de avaliação
  - pode usar um índice sobre saldo para encontrar contas com $saldo < 2500$
  - ou pode realizar varredura completa da relação e descartar contas que não tenham $saldo < 2500$

Processo de Otimização

- Otimização da consulta
  - Entre todos os planos de avaliação equivalentes, escolha aquele com o menor custo
  - O custo é estimado usando informações estatísticas do catálogo de banco de dados
    - Exemplo: número de tuplas em cada relação, tamanho das tuplas etc.
- Objetivo de "Processamento de consultas"
  - Medir custos da consulta
  - Avaliar as operações da álgebra relacional
  - Combinar algoritmos para operações individuais a fim de avaliar uma expressão completa
- No módulo de "Otimização de consultas"
  - Estuda-se como otimizar consultas, ou seja, como encontrar um plano de avaliação com o menor custo estimado

Medidas de custo da consulta

- O custo geralmente é medido como tempo total gasto para responder a consulta
  - Muitos fatores contribuem para o custo de tempo
    - acessos ao disco, CPU, ou mesmo comunicação da rede
- Normalmente, o acesso ao disco é o custo predominante e relativamente fácil de estimar.
  - Leva-se em conta:
    - Número-de-buscas * custo-médio-de-busca
    - Número-de-blocos-lidos * custo-médio-de-leitura-de-bloco
    - Número-de-blocos-escritos * custo-médio-de-escrita-de-bloco
      - Custo para escrever um bloco é maior do que para ler um bloco
- Para simplificar, usamos apenas número de transferências de bloco do disco como medida de custo
  - Pode-se ignorar (para simplificar) a diferente no custo entre E/S sequencial e aleatória
  - Pode-se ignorar (para simplificar) os custos de CPU

Medidas de custo da consulta – influência da memória

- Os custos dependem do tamanho do buffer na memória principal
  - Ter mais memória reduz a necessidade de acesso ao disco
  - A quantidade de memória real disponível para o buffer depende de outros processos concorrente do SO, e é difícil de determinar antes da execução real
  - Normalmente usamos estimativas do pior caso, supondo que apenas a quantidade mínima de memória necessária para a operação esteja disponível

Dominando as operações da álgebra

- Seleção
  - Varredura de arquivo
  - Uso de índice primário
  - Uso de índice secundário
  - Uso combinado de índice
- Ordenação
  - Quick Sort
  - Merge Sort
- Junção
  - Loops Aninhados
  - Hash Join
  - Merge Join

Seleção por varredura de arquivo

- Algoritmo A1 (busca linear)
  - Varra cada bloco de arquivo e teste todos os registros para ver se satisfazem a condição de seleção
  - Estimativa de custo (número de blocos de disco varridos) = $\boldsymbol{b_R}$
    - $\boldsymbol{b_R}$ indica número de blocos contendo registros da relação R
  - A busca linear pode ser aplicada independente de:
    - condição de seleção
    - ordenação dos registros no arquivo
    - disponibilidade de índices

Seleção via índices

- Varredura de índice – algoritmos de busca que usam um índice
  - condição de seleção precisa ser sobre chave de busca do índice
- Tipos
  - Seleção com predicado simples de igualdade (=)
  - Seleção com predicado simples de comparação (<, ≤, > e ≥)
  - Seleção com predicado composto

Seleção com predicado simples de igualdade: uso de índice primário sobre chave candidata

- Algoritmo A2
  - Apanha um único registro que satisfaz a condição de igualdade correspondente
  - $Custo = \boldsymbol{HT_i} + 1$
    - Custo de percorrer o índice + um bloco do arquivo propriamente dito

Seleção com predicado simples de igualdade: uso de índice primário sobre não-chave

- Algoritmo A3: Apanha vários registros
  - Os registros serão sobre blocos consecutivos
  - Custo = $\boldsymbol{HT_i}$ + número de blocos contendo registros apanhados

Seleção com predicado simples de igualdade: uso de índice secundário

- Algoritmo A4
  - Apanhe um único registro se a chave de busca for uma chave candidata
    - Custo = $\boldsymbol{HT_i}$ + 1
  - Apanhe vários registros se a chave de busca não for uma chave candidata
    - Custo = $\boldsymbol{HT_i}$ + número de registros apanhados
      - Pode ser muito dispendioso!
    - Cada registro pode estar em um bloco diferente
    - Um acesso ao bloco para cada registro apanhado

Seleção com predicado simples de comparação

- Considere as seleções na forma $\boldsymbol{\sigma_{A \leq V}(R)}$ ou $\boldsymbol{\sigma_{A \geq V}(R)}$
  - uma varredura de arquivo linear
  - ou usando índices das seguintes maneiras:
- A5 (índice primário sobre A, comparação)
  - Para $\boldsymbol{\sigma_{A \geq V}(R)}$, use índice para encontrar primeira tupla $\geq \boldsymbol{V}$ e varra a relação sequencialmente a partir de lá
  - Para $\boldsymbol{\sigma_{A \leq V}(R)}$, basta varrer a relação sequencialmente até a primeira tupla $> \boldsymbol{V}$; não use índice
- A6 (índice secundário sobre A, comparação)
  - Para $\boldsymbol{\sigma_{A \geq V}(R)}$, use índice para encontrar primeira entrada de índice ≥ v e varra o índice sequencialmente, a partir de lá, para encontrar ponteiros para registros
  - Para $\boldsymbol{\sigma_{A \leq V}(R)}$, basta varrer páginas de folha de índice encontrando ponteiros para registros, até primeira entrada > v
  - De qualquer forma, apanhe registros que são apontados para varredura de arquivo linear pode ser menos custosa se muitos registros tiverem que ser apanhados!

Seleção com predicado composto (conjunção)

- Conjunção: $\boldsymbol{\sigma_{\theta_1 \wedge \theta_2 \wedge \ldots \theta_n}(R)}$
  - Composição de "e"s de predicados simples
- A7 (seleção conjuntiva usando um índice)
  - Selecione uma combinação de $\boldsymbol{\theta_i}$ com um algoritmo (A1 a A6) que resulta no menor custo para $\boldsymbol{\sigma_{\theta_i}(R)}$
  - Teste outras condições na tupla, depois de buscá-la, no buffer da memória
- A8 (seleção conjuntiva usando índice de chave múltiplas)
  - Use o índice composto apropriado (chave múltipla) se estiver disponível
- A9 (seleção conjuntiva por interseção de identificadores)
  - Exige índices com ponteiros de registro
  - Use índice correspondente para cada condição e apanhe a inserção de todos os conjuntos obtidos de ponteiros de registro
  - Apanhe registros do arquivo
  - Se algumas condições não tiverem índices apropriados, aplique o teste na memória

Seleção com predicado composto (disjunção)

- Disjunção: $\boldsymbol{\sigma_{\theta_1 \vee \theta_2 \vee \cdots \theta_n}(R)}$
  - Composição de "ou"s de predicados simples
- A11 (seleção disjuntiva pela união de identificadores)
  - Aplicável se todas as condições tiverem índices disponíveis
    - Caso contrário, use varredura linear
  - Use índice correspondente para cada condição, e apanhe a união de todos os conjuntos obtidos de ponteiros de registro
  - Depois apanhe os registros do arquivo

Seleção com predicado envolvendo negação

- Negação: $\boldsymbol{\sigma_{\neg\theta}(R)}$
  - Use varredura linear no arquivo
  - Se muito poucos registros satisfizerem $\neg\boldsymbol{\theta}$, e um índice for aplicável a $\boldsymbol{\theta}$
    - Encontre registros que satisfazem usando índice e apanhe do arquivo

Ordenação

- Podemos montar um índice sobre a relação, e depois usar o índice para ler a relação na ordem classificada
- Pode levar a um acesso ao bloco de disco para cada tupla
- Para relações que cabem na memória
  - técnicas como quicksort podem ser usadas
- Para relações que não cabem na memória
  - O merge-sort é uma boa escolha

Merge Sort – Princípio Geral

1. Fase de ordenação

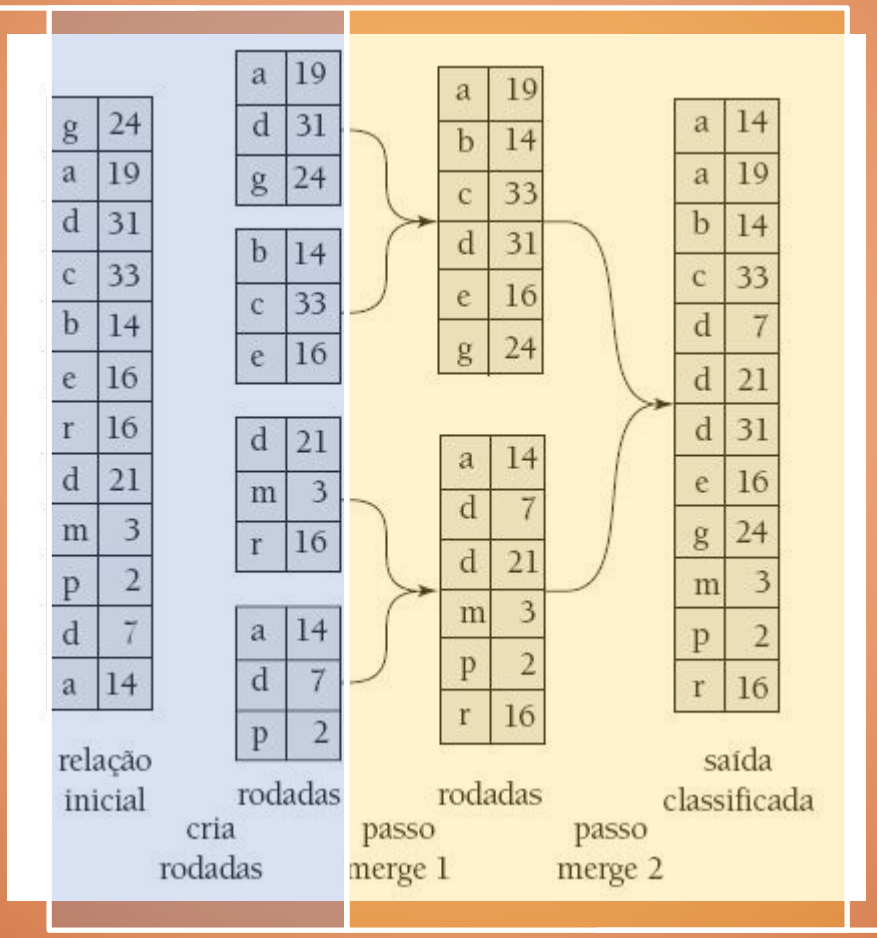

2. Fase de mesclagem ordenada

Sort-merge

- Crie rodadas de M blocos ordenados
- Faça o seguinte repetidamente até o final da relação
  - Leia M blocos da relação para a memória
  - Classifique os M blocos
  - Escreva M blocos classificados
- Mescle as rodadas (mesclagem de $M - 1$ vias)
  - Em cada passada, grupos contíguos de $M - 1$ rodadas são mesclados
  - Uma passada reduz o número de rodadas por um fator de $M - 1$ e cria rodadas maiores pelo mesmo fator
    - Se $M = 11$ e existem 90 rodadas, uma passada reduz o número de rodadas para 9, cada uma 10 vezes o tamanho das rodadas iniciais
  - Passadas repetidas são realizadas até que todas as rodadas tenham sido mescladas em uma única rodada só
  - Note que no slide anterior, $M = 3$
    - 3 blocos por vez na ordenação
    - 2 vias de merge por vez

Complexidade do Merge-Sort

- Cada passagem pela relação envolve a leitura e a escrita da relação toda: $2b_R$
- O número passos de mesclagem exigidas: $\left\lceil log_{M-1}(\frac{b_R}{M}) \right\rceil$
- O número total de acessos ao disco para a classificação externa: $2b_R \left\lceil 1 + log_{M-1}(\frac{b_R}{M}) \right\rceil$
  - 1 refere-se a fase de ordenação
  - $log_{M-1}(\frac{b_R}{M})$ refere-se ao número de fases de mesclagem

Operação de junção

- Vários algoritmos diferentes para implementar junções
  - Junção de loop aninhado
  - Junção de merge
  - Junção de hash
- Escolha baseada em estimativa de custo
- Notação:

  b_R = número de blocos de R

  n_R = número de tuplas em R
- Os exemplos usam a seguinte informação:
  - Número de registros de cliente: 10.000 depositante: 5.000
  - Número de blocos de cliente: 400 depositante: 100

Junção de loop aninhado em bloco

- A variante da junção de loop aninhado em que cada bloco da relação interna é emparelhado com cada bloco da relação externa
  - for each bloco x of R
    for each bloco y of S
      for each tupla t in x
        for each tupla u in y
          if $match(t, u)$
            $\boldsymbol{RS} \leftarrow \boldsymbol{RS} \cup < t, u >$

RS = ResultSet

Junção de loop aninhado em bloco: pior caso

- Cenário de pior caso
  - Memória para ler três blocos por vez
  - Um para cada relação R e S
  - Um para o RS

- Estimativa no pior caso: $\boldsymbol{b_R \times b_S + b_R}$ acessos ao bloco
  - Cada bloco na relação interna S é lido uma vez para cada bloco na relação externa R

Junção de loop aninhado em bloco: melhor caso

- Cenário de melhor caso
  - Memória para ler M blocos por vez
  - $\boldsymbol{b_S} < M$
  - Um para o RS
- Melhor caso: $\boldsymbol{b_R} + \boldsymbol{b_S}$ acessos ao disco
  - Note que para dar certo, a relação interna é que tem que caber na memória

Junção de loop aninhado em bloco: caso geral

- Cenário geral
  - Memória para ler M blocos por vez
  - Ler $M - 2$ blocos de S (relação interna) por vez
  - Um para R (relação externa) e outro para o RS
  - $Custo = \boldsymbol{b_R} \times \left\lceil \frac{\boldsymbol{b_S}}{\boldsymbol{M-2}} \right\rceil + \boldsymbol{b_R}$

Exemplo de custos de junção de loop aninhado

- Calcule depositante ⋈ cliente, com depositante como relação externa
- Número de registros de cliente: 10.000 depositante: 5000
- Número de blocos de cliente: 400 depositante: 100
- Calcule depositante ⋈ cliente no pior caso?
- Calcule depositante ⋈ cliente no melhor caso?
- Calcule depositante ⋈ cliente no caso geral?
- Indique, para cada um dos casos, a relação interna e externa

Junção de merge

- Ordene as duas relações pelos seus atributos de junção
  - Caso já não estejam ordenadas por estes atributos
- Mescle as relações ordenadas para juntá-las
  - A etapa de junção é semelhante ao estágio de mesclagem do algoritmo de sort-merge
  - A principal diferença é o tratamento de valores duplicados no atributo de junção - cada par com o mesmo valor no atributo de junção precisa ser combinado

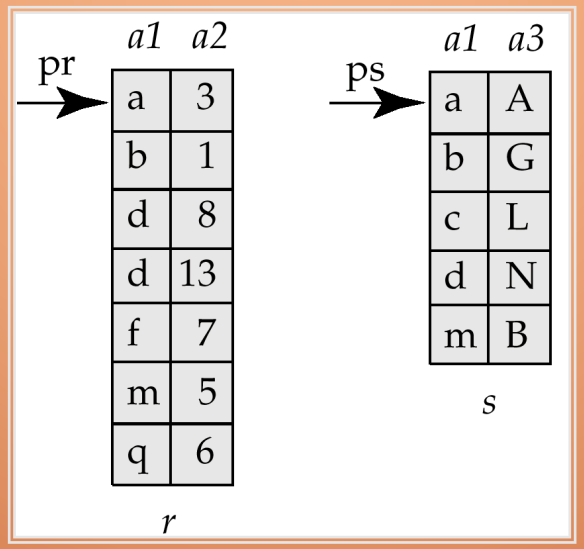

Junção merge (cont.)

- Só pode ser usada para junções de igualdade e naturais
- Cada bloco precisa ser lido uma vez
  - Supondo que todas as tuplas para determinado valor dos atributos de junção caibam na memória
- O número de acessos a bloco para a junção merge é $\boldsymbol{b_R}$ + $\boldsymbol{b_S}$ + custo de ordenar R e S (se não estiverem)

Junção de hash

- Aplicável para equi-junções e junções naturais
- Uma função de hash h é usada para particionar tuplas das duas relações
- h mapeia valores de $JoinAttrs$ para $\{0, 1, \ldots, n\}$, onde $JoinAttrs$ indica os atributos comuns de R e S usados na junção
  - $\boldsymbol{hr_0}$, $\boldsymbol{hr_1}$, ..., $\boldsymbol{hr_n}$ indica partições de r tuplas
    - Cada tupla $tr \in R$ é colocada na partição $\boldsymbol{hr_i}$ onde $i = h(tr, JoinAttrs)$
  - $\boldsymbol{hs_0}$, $\boldsymbol{hs_1}$, ..., $\boldsymbol{hs_n}$ indica partições de s tuplas
    - Cada tupla $\boldsymbol{ts} \in \boldsymbol{S}$ é colocada na partição $\boldsymbol{hs_i}$, onde $i = h(\boldsymbol{ts}, JoinAttrs)$
- No caso geral, o valor de n depende do número M de blocos que podem ficar na memória
  - Quando não o número de blocos não couber na memória, faz-se um particionamento recursivo

Princípio da junção de hash

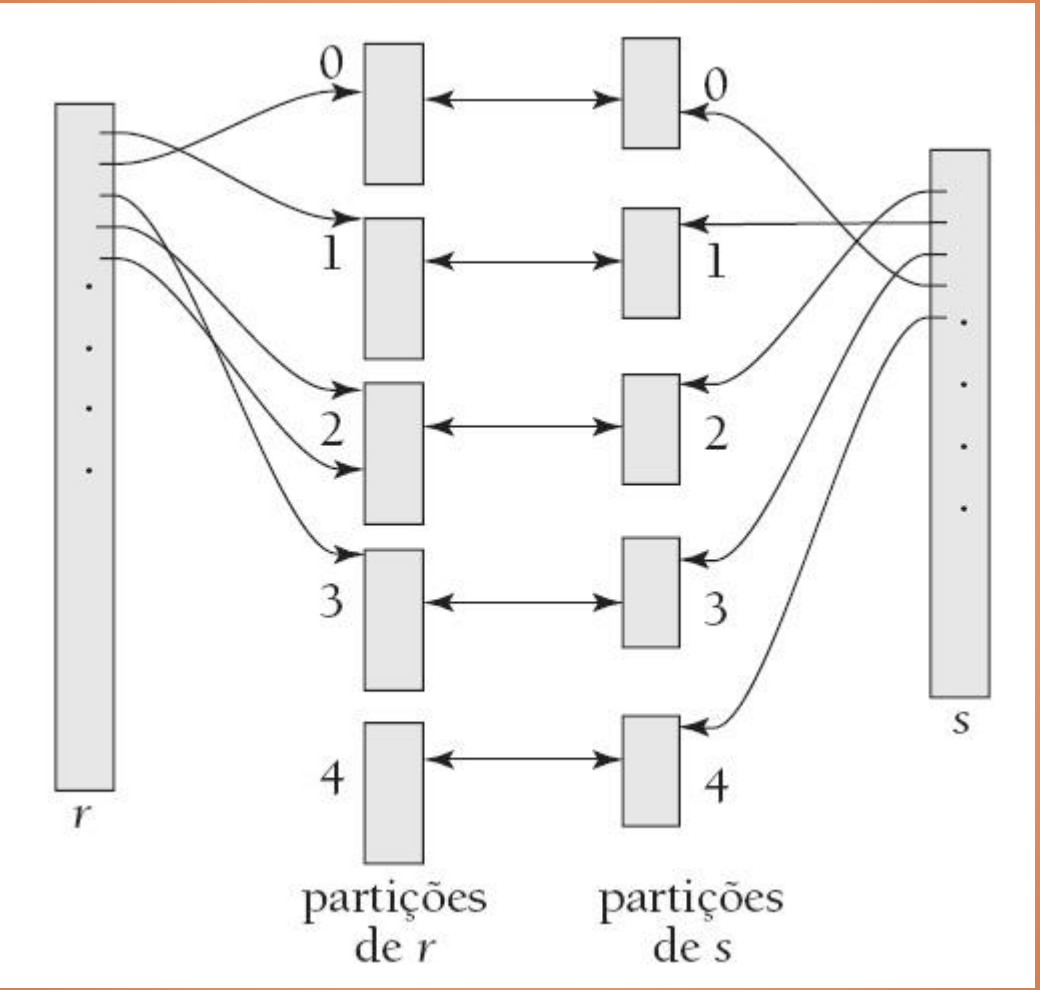

Comparações via junção de hash

- As tuplas da relação R em $\boldsymbol{hr_i}$ só precisam ser comparadas com as tuplas da relação S em $\boldsymbol{hs_i}$
- Elas não precisam ser comparadas com as tuplas s em qualquer outra partição, pois:
  - uma tupla r e uma tupla s que satisfazem a condição de junção tem o mesmo valor para os atributos de junção
  - Se esse valor for transformado por hash em algum valor, a tupla r precisa estar em $\boldsymbol{hr_i}$ e a tupla s em $\boldsymbol{hs_i}$

Custo da junção de hash

- Se o particionamento recursivo não for exigido:
  - custo da junção é aproximadamente $3(\boldsymbol{b_R} + \boldsymbol{b_S})$
    - 2 varreduras para o particionamento e 1 para a junção
- Se o particionamento recursivo for exigido:
  - Custo da junção é $2(\boldsymbol{b_R} + \boldsymbol{b_S})\ [\boldsymbol{log_{M-1}(b_S)} - \mathbf{1}] + \boldsymbol{b_R} + \boldsymbol{b_S}$
    - 2 varreduras por nível de particionamento
    - Número de nível de particionamento é definido por $\boldsymbol{log_{M-1}(b_S)} - \mathbf{1}$

Exemplo de custo de merge join e hash join

- Calcule a junção depositante ⋈ cliente, calcule os custos do mege join e hash-join, considerando o caso mais geral
  - Considere que o tamanho da memória seja de 20 blocos, i.e., $M = 20$
  - $\boldsymbol{b_{depositante} = 100}$ e $\boldsymbol{b_{cliente} = 400}$
- Merge Join
  - $\boldsymbol{Sort_{depositante} = 2b_{depositante}\left\lceil 1 + log_{20-1}(\frac{b_{depositante}}{20})\right\rceil}$
  - $\boldsymbol{Sort_{cliente} = 2b_{cliente}\left\lceil 1 + log_{20-1}(\frac{b_{cliente}}{20})\right\rceil}$
  - Total: $\boldsymbol{b_{depositante} + b_{cliente} + Sort_{depositante} + Sort_{cliente}}$
    - $100 + 400 + 200\lceil \mathbf{1 + log_{19}(5)}\rceil + 800\lceil \mathbf{1 + log_{19}(20)}\rceil$
    - $\boldsymbol{\cong 3300}$
    - Se cliente já estiver ordenado, $\boldsymbol{\cong 900}$
- Hash Join
  - $2(\boldsymbol{b_R + b_S})\ [\boldsymbol{log_{M-1}(b_S) - 1}] + \boldsymbol{b_R + b_S}$
  - $2(\mathbf{100 + 400})\ [\boldsymbol{log_{19}(100) - 1}] + \mathbf{100 + 400}$
  - $\boldsymbol{\cong 1500}$

Avaliação de expressões

- Uma consulta é um conjunto de expressões
  - Expressões são composições de operações individuais
- As alternativas para avaliação de uma árvore de expressão inteira
  - Materialização: gera resultados de uma expressão cujas entradas são relações, originais ou já são calculadas, e materialize (armazene) isso em disco.
  - Pipelining: passe adiante as tuplas para operações ancestrais mesmo quando uma operação está sendo executada

Materialização

- Avaliação materializada: avalie uma operação de cada vez, começando no nível mais baixo.
  - Use resultados intermediários materializados em relações temporárias para avaliar as operações do nível ancestral
  - Por exemplo, na figura a seguir, calcule e armazene
    $\sigma_{saldo < 2500}(conta)$
  - Depois calcule o armazenamento de sua junção com cliente
  - Finalmente, calcule as projeções sobre nome-cliente

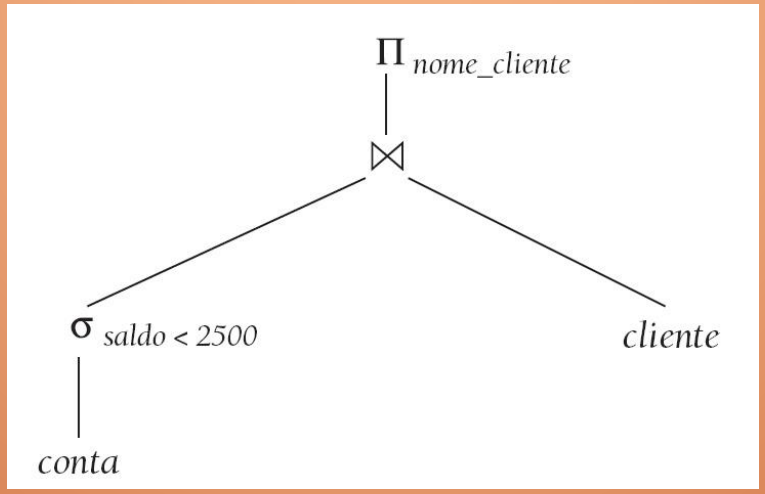

Aspectos da Materialização

- A avaliação materializada sempre é aplicável
- O custo da escrita de resultados em disco e sua leitura de volta pode ser muito alto
  - Nossas fórmulas de custo para as operações ignoram o custo da escrita de resultados em disco, de modo que
    - Custo geral = Soma dos custos de operações individuais + custo da escrita de resultados intermediários em disco
- Buffer duplo: utiliza dois buffers de saída para cada operação, quando uma é a escrita inteira para o disco enquanto a outra está sendo preenchida
  - Permite a sobreposição de escritas de disco com cálculo e reduz o tempo de execução

Pipelining

- Avaliação em pipeline: avalia várias operações simultaneamente, passando os resultados de uma operação para a seguinte
- Por exemplo, na árvore de expressão anterior, não armazene o resultado de $\sigma_{saldo<2500}(conta)$
  - em vez disso, passe tuplas diretamente para a junção
  - De modo semelhante, não armazene o resultado da junção, mas passe tuplas diretamente para a projeção
- O custo computacional é menor quando comparado a materialização: não precisa armazenar uma relação temporária em disco
- O *pipelining* nem sempre pode ser possível, por exemplo, ordenação, junção de hash
- Para que o pipelining seja eficiente, use algoritmos de avaliação que gerem tuplas de saída mesmo quando as tuplas são recebidas para entradas da operação
- As pipelines podem ser executadas de duas maneiras: controladas por demanda e controladas por produtor

Pipelining por demanda

- O sistema repetidamente solicita a próxima tupla da operação de nível superior
  - Cada operação solicita a próxima tupla de operações filhas, conforme a necessidade, a fim de gerar sua próxima tupla
  - Entre as chamadas, a operação precisa manter o "estado", para que saiba o que retornar em seguida
  - Cada operação é implementada como um iterador implementando as seguintes operações
    - open()
      - inicializar varredura de arquivo e ponteiro para início do arquivo como estado
        - Por exemplo: junção de merge: classificar relações e armazenar ponteiros para o início das relações armazenadas como estado
    - next()
      - gerar próxima tupla, e avançar e armazenar ponteiro de arquivo
        - Por exemplo: para junção merge: continuar com merge a partir do estado anterior até a próxima tupla de saída ser encontrada. Salvar ponteiros como estado do iterador
    - close()

Pipelining por produção

- Os operadores produzem tuplas rapidamente e as passam para seus pais
  - Buffer mantido entre operadores, filho coloca tuplas no buffer, pai remove tuplas do buffer
  - Se o buffer estiver cheio, o filho espera até que haja espaço no buffer e depois gera mais tuplas
- O sistema escalona operações que têm espaço no buffer de saída e podem processar mais tuplas de entrada

Algoritmos de avaliação para pipelining

- Alguns algoritmos não são capazes de gerar resultados mesmo quando recebem tuplas de entrada
  - Por exemplo: junção merge, ou junção de hash
  - Estes resultam em resultados intermediários sendo gravados em disco e depois lidos de volta sempre
- Variantes de algoritmo são possíveis para gerar (pelo menos alguns) resultados no ato, enquanto tuplas de entrada são lidas
  - Por exemplo: a junção de hash híbrida gera tuplas mesmo quando tuplas de relação de sonda da partição na memória (partição 0) são lidas
  - Técnica de junção em pipeline: Junção de hash híbrida, modificada para colocar em buffer tanto as tuplas da partição 0 de relações na memória, lendo-as quando estiverem disponíveis, quanto resultados de saída de quaisquer combinações entre as tuplas da partição 0
    - Quando uma nova tupla $r0$ é encontrada, combine-a com tuplas $s0$ existentes, gere combinações de saída e salve-a em $r0$
    - Simetricamente para tuplas $s0$

Referências

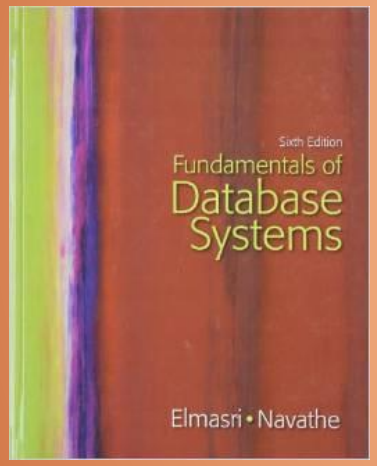

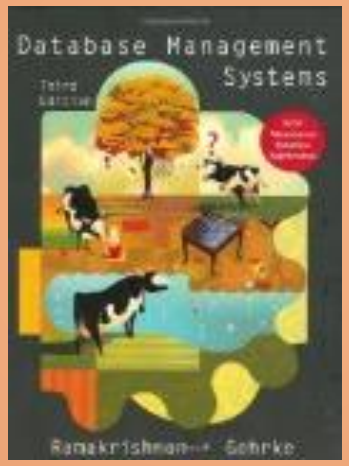

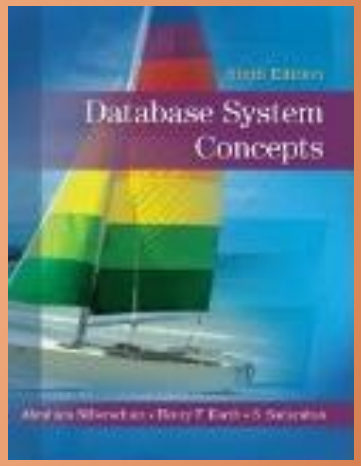

A maioria dos slides apresenta exemplos do livro Database System Concepts